

UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA

MUESTREO HÍBRIDO MEDIANTE REDES DE FLUJO
GENERATIVO Y OPTIMIZACIÓN POR COLONIA DE
HORMIGAS PARA EL PROBLEMA DE ENRUTAMIENTO
DE VEHÍCULOS ESTOCÁSTICO

ANTEPROYECTO DE TESIS

Para obtener el título de:

Ingeniero en Tecnologías de Software

Presenta:

Abraham Castañeda Quintero

Director de Tesis:

Dr. José Arturo Berrones Santos

San Nicolás de los Garza, Nuevo León • 2026

Índice general

Antecedentes Históricos y Teóricos	1
La Barrera de la Estocasticidad y el Marco SVRPBench	4
El Surgimiento de las Redes de Flujo Generativo (GFlowNets)	6
Definición del Problema de Investigación	8
Hipótesis de Trabajo	9
Objetivos de la Investigación	10
Metodología y Diseño Experimental	12
Contribución Científica y Avance de Frontera	15
Viabilidad Operativa y Cronograma de Trabajo	16

Antecedentes Históricos y Teóricos

El campo de la investigación de operaciones y la optimización logística ha estado históricamente dominado por el Problema de Enrutamiento de Vehículos (VRP, por sus siglas en inglés). Concebido formalmente en la década de 1950, el VRP representa uno de los desafíos matemáticos más estudiados en la ciencia de la computación debido a su profunda aplicabilidad industrial en cadenas de suministro, gestión de flotas, logística de última milla y redes de transporte. El objetivo fundamental del VRP es diseñar un conjunto de rutas óptimas para una flota de vehículos que deben atender a una serie de clientes distribuidos geográficamente, minimizando el costo total operativo sujeto a restricciones estrictas como la capacidad máxima de carga de los vehículos, ventanas de tiempo de servicio obligatorias y tiempos máximos de jornada laboral [1].

Desde la perspectiva de la complejidad computacional, el VRP y sus múltiples variantes pertenecen a la clase de problemas NP-duros [2]. Esto implica que el tiempo requerido para encontrar una solución globalmente óptima escala de manera exponencial conforme aumenta el número de clientes o nodos en el grafo. Históricamente, la comunidad científica abordó este problema a través de tres grandes paradigmas. El primer paradigma incluye los métodos exactos, fundamentados en algoritmos de ramificación y acotación (*branch-and-bound*), planos de corte (*branch-and-cut*) y programación dinámica. Si bien estos enfoques garantizan matemáticamente la identificación del óptimo global, su aplicabilidad se restringe severamente a instancias de tamaño reducido debido a la intratabilidad computacional, volviéndolos inoperantes en escenarios de logística urbana masiva donde el número de nodos supera los varios cientos o miles de clientes.

Para sortear las barreras de la intratabilidad matemática, el segundo paradigma emergió en la forma de algoritmos heurísticos y metaheurísticas. Métodos como el Recocido Simulado (*Simulated Annealing*), la Búsqueda Tabú (*Tabu Search*), los Algoritmos Genéticos y la Optimización por Colonia de Hormigas (*Ant Colony Optimization*, ACO) dominaron el estado del arte industrial durante décadas [3]. Estas metaheurísticas sacrifican la garantía de optimalidad global a cambio de encontrar soluciones subóptimas de muy alta calidad en tiempos de cómputo polinomiales. En particular, la Optimización por Colonia de Hormigas

se destacó por su capacidad para explorar vastos espacios de solución topológicos mediante el despliegue de múltiples agentes concurrentes que construyen rutas de forma estocástica, depositando rastros de feromona virtual que alteran las probabilidades de transición en iteraciones futuras [3]. Sin embargo, la limitación inherente de todas las metaheurísticas clásicas radica en su dependencia extrema del diseño manual de reglas empíricas, la calibración artesanal de hiperparámetros específicos para cada distribución de datos, y una ejecución computacional desde cero para cada nueva instancia del problema. Cada vez que cambia el mapa de clientes, la metaheurística debe reiniciar su proceso iterativo, lo que impide su uso eficiente en aplicaciones de enrutamiento dinámico en tiempo real.

El tercer y más reciente paradigma es la Optimización Combinatoria Neuronal (NCO, por sus siglas en inglés). Impulsada por los avances masivos en el aprendizaje profundo (*Deep Learning*) y el procesamiento de secuencias, la NCO busca reemplazar el diseño de reglas heurísticas manuales con redes neuronales parametrizadas que aprenden a mapear directamente las características geométricas y espaciales de un problema hacia una solución óptima [4]. Los enfoques iniciales utilizaron Redes de Apuntadores (*Pointer Networks*) y arquitecturas recurrentes entrenadas mediante aprendizaje supervisado. No obstante, el aprendizaje supervisado exigía la generación previa de millones de rutas óptimas mediante solucionadores exactos lentos para actuar como etiquetas de entrenamiento, un proceso que resultó ser un cuello de botella inasumible para problemas a gran escala.

En consecuencia, el Aprendizaje por Refuerzo (*Reinforcement Learning*, RL) se consolidó como el motor de entrenamiento dominante en NCO. A través de algoritmos como REINFORCE y esquemas de Actor-Crítico, los modelos neuronales aprendieron a optimizar las rutas explorando el entorno y utilizando el costo final de la ruta generada como señal de recompensa, eliminando por completo la necesidad de datos etiquetados. El hito más significativo en este paradigma fue la introducción de la arquitectura de Modelo de Atención (*Attention Model*) combinada con la estrategia de Optimización de Política con Múltiples Óptimos (POMO) [4], [5]. POMO revolucionó la resolución neuronal al explotar las simetrías inherentes del VRP: una ruta es equivalente independientemente del nodo desde el cual el vehículo inicie su recorrido. Al forzar a la red neuronal a generar múltiples trayectorias simultáneas comenzando desde diferentes nodos óptimos y utilizando la media de estas recompensas como una línea base compartida de bajo sesgo y baja varianza, POMO estabilizó dramáticamente el entrenamiento, permitiendo que arquitecturas basadas en Transformers resolvieran instancias deterministas de VRP con cien clientes en fracciones de segundo y con brechas de optimalidad mínimas respecto a los solucionadores algorítmicos [4], [6].

Cuadro 1: Paradigmas de Optimización para el Enrutamiento de Vehículos

Paradigma	Ventaja Principal	Desventaja Crítica	Escalabilidad
Métodos Exactos (Branch & Cut)	Garantizan el óptimo global con certeza matemática.	Intratabilidad temporal por explosión combinatoria.	Muy Baja (< 100 nodos)
Metaheurísticas Clásicas (ACO, Tabu)	Soluciones de alta calidad sin entrenamiento previo.	Requieren ejecución desde cero; diseño manual.	Moderada (100 - 1000 nodos)
NCO (RL Supervisado)	Inferencia rápida tras el entrenamiento.	Dependencia total de datos etiquetados caros.	Baja (Limitada por datos)
NCO (RL Determinista) (POMO, AM)	Inferencia en milisegundos; entrenamiento sin etiquetas.	Fragilidad extrema ante estocasticidad; colapso de modos.	Alta (> 1000 nodos en entornos estáticos)

La Barrera de la Estocasticidad y el Marco SVRPBench

A pesar de la madurez matemática y el éxito empírico de la Optimización Combinatoria Neuronal basada en POMO y modelos de atención, la translación de estos sistemas a la logística urbana real ha revelado vulnerabilidades estructurales catastróficas. El modelo matemático tradicional del VRP asume un universo puramente estático y determinista: los tiempos de viaje entre el nodo A y el nodo B son constantes inmutables, la presencia del cliente está garantizada, y las demandas son conocidas a priori con exactitud milimétrica. Esta idealización es profundamente incompatible con la naturaleza entrópica de las cadenas de suministro modernas [1].

El Problema de Enrutamiento de Vehículos Estocástico (SVRP, por sus siglas en inglés) surge como la formulación rigurosa que incorpora la incertidumbre explícita dentro de las variables de decisión. En el SVRP, componentes críticos como la velocidad de tránsito, el tiempo de servicio in situ, y las fluctuaciones de la demanda se modelan como variables aleatorias extraídas de distribuciones de probabilidad complejas. En este régimen incierto, una ruta que es matemáticamente óptima bajo asunciones deterministas puede volverse inviable o incurrir en costos astronómicos de penalización en el mundo real.

Para estudiar científicamente este fenómeno y proporcionar una arena de evaluación estandarizada, la literatura reciente ha introducido el marco **SVRPBench** (*Stochastic Vehicle Routing Problem Benchmark*) [1]. **SVRPBench** representa la plataforma de simulación de alta fidelidad más avanzada hasta la fecha, diseñada para inyectar dinámicas estocásticas a escala urbana que reflejan meticulosamente las condiciones logísticas empíricas. El marco desafía a la comunidad de inteligencia artificial al modelar la incertidumbre a través de cuatro vectores estocásticos fundamentales, cada uno fundamentado en análisis empíricos de tráfico y comportamiento logístico urbano [1]:

- 1. Congestión Dependiente del Tiempo mediante Mezclas Gaussianas:** **SVRPBench** abandona la velocidad de tránsito euclidiana simple. En su lugar, parametriza la congestión vial utilizando distribuciones de mezcla gaussiana (*Gaussian*

Mixtures) que simulan con precisión los picos de tráfico durante las horas de mayor afluencia.

- 2. Retrasos Estocásticos Modelados con Distribuciones Log-Normales:** Las demoras no siguen una distribución normal simétrica. La mayoría de los viajes ocurren sin incidentes, pero ocasionalmente ocurren retrasos severos. La distribución log-normal captura esta asimetría de cola pesada (*heavy-tailed*).
- 3. Disrupciones por Accidentes mediante Procesos de Poisson:** Introduce la probabilidad discreta de accidentes de tránsito modelados a través de procesos de Poisson, que imponen fallos sistémicos localizados que pueden invalidar segmentos enteros del grafo combinatorio.
- 4. Ventanas de Tiempo Heterogéneas y Empíricas:** Las disponibilidades se dividen en distribuciones comerciales y residenciales asimétricas.

La evaluación rigurosa de las arquitecturas de NCO del estado del arte bajo el marco **SVRPBench** ha arrojado conclusiones preocupantes: los modelos neuronales deterministas dominantes sufren una degradación de rendimiento masiva que supera el 20 % frente a los desplazamientos distribucionales inducidos por la incertidumbre estocástica [1]. Al haber sido entrenados para maximizar una recompensa estática, estos modelos colapsan en modos singulares, perdiendo la diversidad representacional necesaria para implementar planes de contingencia eficientes.

El Surgimiento de las Redes de Flujo Generativo (GFlowNets)

Frente a la vulnerabilidad estructural del Aprendizaje por Refuerzo estándar ante el SVRP, las Redes de Flujo Generativo (Generative Flow Networks o GFlowNets) emergen como un paradigma probabilístico fundamentado teóricamente para resolver problemas de diversidad en espacios combinatorios [7]. Las GFlowNets abandonan el objetivo exclusivo de maximización de recompensas. En cambio, su objetivo de optimización es aprender una política estocástica secuencial que construya objetos composicionales discretos con una probabilidad de muestreo que sea estrictamente proporcional a una función de recompensa no normalizada.

La matemática subyacente de las GFlowNets modela el espacio de solución como un Grafo Acíclico Dirigido (DAG), $\mathcal{G} = (\mathcal{V}, \mathcal{E})$. El estado inicial s_0 representa una solución vacía. Cada transición dirigida representa una acción constructiva válida, llevando a un nuevo estado parcial. Los estados terminales, denominados $x \in \mathcal{X}$, representan soluciones completas y evaluables. Las GFlowNets entrenan una red neuronal para garantizar que la suma de los flujos que ingresan a un estado parcial sea igual a la suma de los flujos que salen del mismo hacia todos sus posibles hijos [7]. Cuando esta condición de conservación de Markov se cumple, el modelo induce una política de avance P_F y una política de retroceso P_B que alinean $P_T(x) \propto R(x)$ de forma exacta.

Para entrenar estas políticas en problemas complejos, la literatura introdujo el objetivo de Balance de Trayectoria (Trajectory Balance, TB) [8], que optimiza las políticas a lo largo de una trayectoria completa $\tau = (s_0 \rightarrow \dots \rightarrow s_n)$:

$$\mathcal{L}_{TB}(\tau; \theta) = \left(\log \frac{Z_\theta \prod_{t=0}^{n-1} P_F(s_{t+1}|s_t; \theta)}{\prod_{t=0}^{n-1} P_B(s_t|s_{t+1}; \theta) R(s_n)} \right)^2 \quad (1)$$

A pesar del éxito del TB, investigaciones de frontera han detectado inestabilidades locales severas debido a que TB evalúa la trayectoria de forma holística, ignorando microestructuras locales importantes en el enrutamiento [9]. Para mitigar esto, se ha reintroducido el principio de Balance Detallado (Detailed Balance, DB) a nivel de transición atómica:

$$\mathcal{L}_{DB}(s, s'; \theta) = \left(\log \frac{F_\theta(s) P_F(s'|s; \theta)}{F_\theta(s') P_B(s|s'; \theta)} \right)^2 \quad (2)$$

La vanguardia del estado del arte actual es la arquitectura Hybrid-Balance GFlowNet (HBG), una fusión sinérgica que amalgama las fortalezas globalizadoras del TB con la consistencia microscópica del DB de manera adaptativa para resolver problemas de ruteo [9]. Adicionalmente, mediante la integración de Redes Neuronales Epistémicas (ENN), se dota al modelo de la capacidad de cuantificar la incertidumbre de sus propias predicciones y guiar activamente la exploración de nuevas rutas [10].

Definición del Problema de Investigación

El estado del arte actual presenta una segmentación tecnológica crítica. Por un lado, la Optimización Combinatoria Neuronal basada en Aprendizaje por Refuerzo puro (como POMDP) logra eficiencias computacionales notables pero fracasa espectacularmente frente a la incertidumbre estocástica urbana, colapsando ante variaciones distribucionales. Por otro lado, la investigación en Generative Flow Networks ha alcanzado formulaciones matemáticamente ricas, como el esquema Hybrid-Balance y la parametrización epistémica, capaces de modelar la diversidad y el riesgo, pero que carecen de validación sobre entornos estocásticos de alta fidelidad orientados a la logística.

En síntesis, el problema de investigación se formula a través de la siguiente pregunta científica:

«¿Es posible mejorar de forma estadísticamente significativa la robustez y viabilidad táctica de soluciones para el problema de ruteo estocástico mediante un marco híbrido que combine el muestreo adaptativo de una red neuronal Hybrid-Balance GFlowNet con el refinamiento poblacional de colonias de hormigas estocásticas?»

Hipótesis de Trabajo

Hipótesis General

La integración arquitectónica de una Red de Flujo Generativo con Balance Híbrido (HBG) y cuantificación de incertidumbre epistémica (ENN) como parametrizador a priori dentro de un enjambre estocástico paralelo (ACO), entrenada bajo la infraestructura desacoplada de RL4CO, producirá un motor de búsqueda combinatorio neuronal capaz de superar estadísticamente en robustez (tasa de factibilidad y costo esperado bajo ruido log-normal y interrupciones de Poisson) a los métodos neuronales deterministas (POMO, AM) y a las heurísticas industriales convencionales en el marco de simulación **SVRPBench**, manteniendo tiempos de inferencia competitivos frente a dichas heurísticas.

Hipótesis Específicas

- H1.** La incorporación explícita de la penalización de Balance Detallado (DB) junto al Balance de Trayectoria (TB) mitigará los picos de pérdida asintóticos en espacios complejos, mejorando la convergencia en instancias con ventanas de tiempo rígidas.
- H2.** La retroalimentación asíncrona de trayectorias estocásticas desde el motor de Colonia de Hormigas hacia el búfer fuera de política de la GFlowNet incrementará la diversidad del hiperespacio de soluciones generado, limitando el colapso de modo.
- H3.** La cuantificación activa de la incertidumbre epistémica mediante Redes Neuronales Epistémicas guiará el muestreo hacia regiones poco exploradas del espacio de soluciones, incrementando la diversidad de rutas candidatas factibles y, en sinergia con el refinamiento poblacional del ACO, facilitando la identificación de rutas de recurso resilientes frente a los retrasos log-normales y las interrupciones de Poisson.

Objetivos de la Investigación

Objetivo General

Desarrollar y validar un marco algorítmico híbrido que acople una Red de Flujo Generativo de Balance Híbrido (HBG) con un muestreador de Colonia de Hormigas (*Generative Flow Ant Colony Sampler*, GFACS) —núcleo denominado HBG-FACS— para la optimización robusta del Problema de Enrutamiento de Vehículos Estocástico de escala pequeña y media, simulado en alta fidelidad mediante **SVRPBench**. Como extensión exploratoria se incorporará un módulo de incertidumbre epistémica (ENN), configurando el marco completo *Epistemic* HBG-FACS (EHBG-FACS), y se evaluará la escalabilidad a instancias de mayor tamaño.

Objetivos Específicos

- OE1.** Integrar el marco **SVRPBench** dentro de la librería modular **RL4CO**, automatizando la generación de instancias urbanas dinámicas de escala pequeña y media (50 a 300 nodos).
- OE2.** Diseñar e implementar en PyTorch una arquitectura codificador-decodificador basada en Transformers, parametrizada como una GFlowNet de Balance Híbrido (HBG).
- OE3.** Acoplar la política estocástica de la GFlowNet con el muestreador metaheurístico de Colonia de Hormigas (GFACS) y un búfer fuera de política, conformando el núcleo HBG-FACS.
- OE4.** Cuantificar empíricamente el desempeño del modelo en calidad de solución (brecha de optimalidad y costo esperado), tasa de factibilidad y tiempos de inferencia, frente a métodos del estado del arte (POMO, AM y heurísticas clásicas), con validación estadística.

OE5. (*Exploratorio*) Incorporar el módulo epistémico (ENN) para guiar la exploración y evaluar la escalabilidad del marco a configuraciones multi-depósito y de gran escala (> 500 nodos), según la disponibilidad de tiempo y cómputo.

Metodología y Diseño Experimental

La investigación adopta una metodología experimental cuantitativa estructurada en cinco fases de ejecución sobre la biblioteca modular **RL4CO** [6]:

Fase 1: Configuración del Ecosistema de Benchmarking

La base de simulación consistirá en el ecosistema **SVRPBench** [1]. El alcance comprometido se centrará en dos categorías topológicas de escala abordable: instancias de pequeña escala (50 a 100 nodos) y de escala media (100 a 300 nodos), con configuración principal de depósito único. A cada arco geográfico se le inyectarán las distribuciones dinámicas descritas: perfiles bimodales de tráfico usando mezclas gaussianas, retardos log-normales asimétricos y penalizaciones temporales modeladas por procesos de Poisson. Las configuraciones multi-depósito y de gran escala (> 500 nodos) se reservan como pruebas de escalabilidad exploratorias (Fase 5).

Sobre este simulador se adopta una formulación de **programación estocástica en dos etapas con recurso** [11]. En la primera etapa se decide la ruta *a priori*, antes de observar la realización del escenario aleatorio ξ (congestión, retrasos log-normales y accidentes de Poisson); en la segunda etapa, cuando una ruta resulta inviable —por ejemplo, una ventana de tiempo violada o un arco bloqueado por un accidente—, se aplica una **política de recurso** (reordenamiento local o retorno al depósito) con un costo asociado $Q(\text{ruta}, \xi)$. El costo total de una solución es entonces $c(\text{ruta}) + Q(\text{ruta}, \xi)$, estimado por simulación Monte Carlo sobre múltiples escenarios.

Dado que las distribuciones de costo resultantes presentan colas pesadas, la señal de recompensa de la GFlowNet no se basará únicamente en el costo esperado, sino en una medida sensible al riesgo: el **Valor en Riesgo Condicional** (CVaR) [12]. Para un nivel de confianza α , CVaR_α corresponde al costo esperado en el peor $(1 - \alpha)$ de los escenarios; así, una recompensa de la forma $R(x) \propto \exp(-\text{CVaR}_\alpha(c + Q)/T)$ privilegia rutas robustas frente a las interrupciones de cola y no sólo de bajo costo promedio, donde T es la temperatura de flujo del Cuadro 2.

Fase 2: Diseño del Modelo Neuronal Codificador-Decodificador HBG

La arquitectura profunda será programada en PyTorch. El módulo codificador implementará un Transformer Gráfico (*Graph Transformer*) modificado que procesará características estáticas de los clientes y variables de varianza temporal de tráfico. El módulo decodificador calculará el flujo de estado $F_\theta(s)$ y parametrizará la política de avance $P_F(s'|s; \theta)$ y de retroceso $P_B(s|s'; \theta)$. El bucle de entrenamiento unificará de manera adaptativa los objetivos de Balance de Trayectoria (TB) y Balance Detallado (DB) mediante el esquema HBG [9].

Fase 3: Sinergia Metaheurística con Colonia de Hormigas (GFACS)

Una vez entrenada la política HBG, en lugar de una decodificación puramente codiciosa, las probabilidades calculadas por la política neuronal P_F poblarán la matriz de heurística a priori de un algoritmo de Colonia de Hormigas (ACO) [13]. Múltiples enjambres virtuales procesarán iteraciones estocásticas de simulación de tráfico; las trayectorias que demuestren mayor robustez actualizarán la matriz de feromona. El sistema empleará un búfer de repetición fuera de política (*off-policy replay buffer*) para retroalimentar estas soluciones exitosas hacia la red GFlowNet, conformando el núcleo HBG-FACS.

Fase 4: Validación Experimental y Optimización de Hiperparámetros

Se evaluará el núcleo HBG-FACS frente a líneas base representativas —POMO, el *Attention Model* (AM) y heurísticas clásicas— en términos de tasa de factibilidad, costo esperado y tiempos de inferencia bajo las dinámicas estocásticas de **SVRPBench**. Los hiperparámetros críticos se sintonizarán mediante la librería Optuna [14]. La significancia de las diferencias se contrastará mediante análisis de varianza (ANOVA) con un nivel de significancia de $\alpha = 0.05$, complementado con pruebas no paramétricas (p.ej. Friedman o Wilcoxon) cuando no se satisfagan los supuestos de normalidad y homocedasticidad, dada la naturaleza de cola pesada de los costos de ruteo.

Fase 5: Extensión Epistémica (ENN) y Escalabilidad (exploratoria)

Como extensión opcional, condicionada a la disponibilidad de tiempo y cómputo, se aplicará una modificación en la capa final de la red de política para transformarla en una Red Neuronal Epistémica (ENN) mediante el esquema *epinet*, extendiendo dicha capa en un conjunto (*ensemble*) de cabezas indexadas que comparten el cuerpo de la red [10]. La incertidumbre epistémica estimada guiará la exploración hacia subgrafos poco visitados, incrementando la diversidad de rutas candidatas factibles, mientras que la robustez ante las disrupciones (retrasos log-normales y accidentes de Poisson) emerge de la combinación entre dicha diversidad y el refinamiento poblacional del ACO. En esta fase también se explorará la escalabilidad del marco a configuraciones multi-depósito y de gran escala (> 500 nodos).

Cuadro 2: Espacio de búsqueda de hiperparámetros del sistema EHBG-FACS

Hiperparámetro Sistémico	Espacio de Búsqueda	Módulo Impactado
Coefficiente HBG (λ_{DB})	Uniforme: [0.1, 0.9]	Ponderación de pérdida TB vs. DB
Tasa de Evaporación (ρ)	Log-Uniforme: $[10^{-3}, 10^{-1}]$	Dinámica de feromonas en ACO
Temperatura de Flujo (T)	Uniforme: [0.5, 5.0]	Suavizado de la política P_F
Tasa de Aprendizaje AdamW	Log-Uniforme: $[10^{-5}, 10^{-3}]$	Codificador-decodificador Transformer

Contribución Científica y Avance de Frontera


La ejecución del anteproyecto propuesto aportará tres contribuciones fundamentales a la ciencia de la computación y la investigación de operaciones:

- C1. Fundamentación de un Paradigma Híbrido Estocástico:** El estudio aportará una formalización documentada del acoplamiento HBG–GFACS para el ruteo estocástico de alta fidelidad y, como extensión, su unificación con redes epistémicas (ENN), dotando a las GFlowNets de resiliencia explícita ante perturbaciones de recompensa urbana estocástica [9], [10].
- C2. Integración Asíncrona de Redes Profundas y Metaheurísticas:** Se validará de forma empírica el uso de distribuciones neuronales probabilísticas completas (en lugar de puntuaciones de aristas manuales) para inicializar búsquedas descentralizadas masivamente paralelas (ACO) en entornos de tráfico dinámicos.
- C3. Liberación de un Framework Reproducible de Ruteo Tolerante a Fallos:** Toda la base del ecosistema EHBG–FACS, construido sobre la estructura desacoplada de RL4CO, se depositará en un repositorio de código abierto para su libre utilización industrial y científica [6].

Viabilidad Operativa y Cronograma de Trabajo

El proyecto está calendarizado para ejecutarse en el transcurso de seis meses. La viabilidad técnica se apoya en el uso de la librería modular `RL4C0` —construida sobre PyTorch y PyTorch Lightning— ejecutada sobre infraestructura de cómputo acelerada por GPU, lo que reduce significativamente la sobrecarga ingenieril al reutilizar los entornos, modelos y rutinas de entrenamiento ya implementados para optimización combinatoria.

Cuadro 3: Cronograma tentativo de actividades (6 meses)



Bibliografía

- [1] A. Heakl, Y. S. Shaaban, M. Takáč, S. Lahlou y Z. Iklassov, «SVRPBench: A Realistic Benchmark for Stochastic Vehicle Routing Problem,» *arXiv preprint arXiv:2505.21887*, 2025.
- [2] J. K. Lenstra y A. H. G. Rinnooy Kan, «Complexity of vehicle routing and scheduling problems,» *Networks*, vol. 11, n.º 2, págs. 221-227, 1981.
- [3] M. Dorigo, V. Maniezzo y A. Colorni, «Ant System: Optimization by a Colony of Cooperating Agents,» *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol. 26, n.º 1, págs. 29-41, 1996.
- [4] Y.-D. Kwon, J. Choo, B. Kim, I. Yoon, Y. Gwon y S. Min, «POMO: Policy Optimization with Multiple Optima for Reinforcement Learning,» en *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, págs. 21 188-21 198.
- [5] W. Kool, H. van Hoof y M. Welling, «Attention, Learn to Solve Routing Problems!» En *International Conference on Learning Representations (ICLR)*, 2019.
- [6] F. Berto et al., «RL4CO: an Extensive Reinforcement Learning for Combinatorial Optimization Benchmark,» en *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '25)*, 2025.
- [7] Y. Bengio, S. Lahlou, T. Deleu, E. J. Hu, M. Tiwari y E. Bengio, «GFlowNet Foundations,» *Journal of Machine Learning Research*, vol. 24, págs. 1-76, 2023.
- [8] N. Malkin, M. Jain, E. Bengio, C. Sun e Y. Bengio, «Trajectory balance: Improved credit assignment in gflownets,» en *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, págs. 5955-5967.
- [9] N. Zhang y Z. Cao, «Hybrid-Balance GFlowNet for Solving Vehicle Routing Problems,» en *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [10] S. Muhammad y S. Lahlou, «Improved Exploration in GFlowNets via Enhanced Epistemic Neural Networks,» *arXiv preprint arXiv:2506.16313*, 2025.

- [11] M. Gendreau, G. Laporte y R. Séguin, «Stochastic vehicle routing,» *European Journal of Operational Research*, vol. 88, n.º 1, págs. 3-12, 1996.
- [12] R. T. Rockafellar y S. Uryasev, «Optimization of Conditional Value-at-Risk,» *Journal of Risk*, vol. 2, n.º 3, págs. 21-41, 2000.
- [13] M. Kim, S. Choi, H. Kim, J. Son, J. Park e Y. Bengio, «Ant Colony Sampling with GFlowNets for Combinatorial Optimization,» en *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2025.
- [14] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, «Optuna: A Next-Generation Hyperparameter Optimization Framework,» en *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019, págs. 2623-2631.